

Pipeline de prediccion de viviendas

Documentacion tecnica de arquitectura, seguridad y ejecucion

Google Cloud: BigQuery, Cloud Storage, Vertex AI Pipelines, Cloud Run Jobs y Cloud Scheduler

Documento generado a partir de la implementacion y evidencias del proyecto.

1. Resumen

El proyecto implementa un proceso automatizado de inferencia de Machine Learning para registros de viviendas. Lee datos desde BigQuery, aplica las mismas transformaciones usadas durante el entrenamiento, ejecuta un modelo previamente entrenado y publica los resultados en BigQuery.

La solución separa la fuente de datos, el procesamiento y la publicación de resultados en tres proyectos de Google Cloud. La ejecución se programa con Cloud Scheduler, se inicia mediante Cloud Run Job y se orquesta en Vertex AI Pipelines.

2. Arquitectura

Capa	Proyecto	Responsabilidad
Input	gcp-data-bigquery-prod-us-east	Almacena la tabla fuente hist_table.input_data.
Processing	gcp-processing-vertex-prod-us	Ejecuta Cloud Run, Vertex AI, BigQuery temporal y Cloud Storage.
Output	gcp-output-bigquery-prod-us-ea	Publica las tablas historica y de ultima vista.

Flujo de ejecucion

1	Cloud Scheduler	Programa la ejecucion del Job.
2	Cloud Run Job	Resuelve el periodo y envia el Pipeline Job a Vertex AI.
3	Vertex AI Pipelines	Filtra, transforma, predice y publica resultados.
4	BigQuery Output	Recibe la tabla historica y la ultima vista.

Diagramas editables

Los archivos **Diagrama_Proyecto.drawio** y **Diagrama_GSA.drawio** se entregan junto con el proyecto. El primero describe el flujo de datos y recursos; el segundo, las cuentas de servicio y las relaciones IAM. Pueden abrirse y editarse con diagrams.net.

3. Recursos implementados

Ubicacion	Recurso	Uso
Input	hist_table.input_data	Datos fuente filtrados por periodo.
Processing	dev_table.features_input	Catalogo y orden de variables del modelo.
Processing	temp_data_input / transformed / predict	Persistencia de resultados intermedios.
Processing	model_execution_audit	Auditoria de ejecucion, modelo y ruta.
Output	ba_aux_modelo_universo	Ultima vista del universo procesado.
Output	ba_modelo_propension_inscripcion	Historico de predicciones.

4. Proceso de datos y modelo

El Cloud Run Job recibe el parametro **--periodo** en formato AAAAMM. Si se omite o se usa AUTO, consulta el MAX(periodo) de la tabla fuente. Luego genera un run_id para trazabilidad y envia los parametros al Pipeline Job de Vertex AI.

Componente	Funcion
FILTER DATA INPUT	Lee los datos fuente y conserva las variables requeridas.
TRANSFORM DATA	Aplica el pipeline de transformacion entrenado: imputacion, codificacion y escalamiento.
PROCESS PREDICT	Carga el modelo .joblib, calcula la prediccion y registra auditoria.
SEND OUT	Publica la ultima vista y el historico en el proyecto Output.

Artefactos

Cloud Storage centraliza los artefactos de inferencia: Model-GradientBoostingRegressor.joblib, Pipeline-Transformacion-Training.joblib, metadata_transformer.py y la especificacion compilada pipeline-processing-predict.json.

5. Seguridad e IAM

Cuenta de servicio	Funcion
sa-scheduler-scheduler-prod-01	Ejecuta o invoca el Cloud Run Job desde Scheduler.
sa-crun-crun-prod-01	Ejecuta el contenedor de Cloud Run y envia el Pipeline Job.
sa-processing-crun-vertex-prod	Ejecuta los componentes de Vertex AI.
sa-admin-storage-prod-01	Administracion de objetos de Cloud Storage.
sa-data-adm-bigquery-prod-01	Administracion de recursos de BigQuery.

Principio de ejecucion

Cada recurso usa la cuenta de servicio que tiene adjunta. Service Account User permite indicar una cuenta de servicio al enviar un recurso, pero no hereda automaticamente permisos de BigQuery o Cloud Storage. La GSA de Vertex debe tener permisos directos para leer, escribir y crear los trabajos que ejecutan los componentes.

Recurso	Permiso principal
BigQuery Processing	BigQuery Job User y BigQuery Data Editor.
BigQuery Input	BigQuery Data Viewer.
BigQuery Output	BigQuery Data Editor y Data Viewer.
Cloud Storage	Storage Object Viewer / Object User.
Vertex AI	Vertex AI User.
Cloud Run / Vertex GSA	Service Account User.

6. Evidencias de ejecucion

Las siguientes capturas validan la ejecucion automatizada y la disponibilidad de los recursos del pipeline.




Figura 1. Cloud Scheduler registra una ejecucion sin errores.




Figura 2. Historial del Cloud Run Job ejecutado.




Figura 3. Tarea de Cloud Run finalizada con codigo de salida 0.




Figura 4. Ejecucion iniciada en Vertex AI Pipelines.




Figura 5. Grafo de Vertex AI con todos los componentes completados correctamente.

7. Evidencias de recursos y permisos




Figura 6. Roles IAM del proyecto Processing.




Figura 7. Acceso de Cloud Run a la cuenta de servicio de Vertex AI.




Figura 8. Acceso de Scheduler a la cuenta de servicio utilizada por Cloud Run.




Figura 9. Permiso de BigQuery en el proyecto Input.





Figura 10. Configuración IAM del proyecto Output.

8. Evidencias de datos y artefactos



Google Cloud BigQuery - gcp-processing-vertex-prod-us

dev_table


Descripción general Detalles Estadísticas

Tablas Gráficos Modelos Rutinas

Filtro Escribir el nombre o valor de la propiedad

ID de tabla	Tipo	Fecha de creación	Hora de vencimiento	Etiqueta	
features_input	Tabla	5 ago 2026, 1:06:25 a.m. UTC-5	Ninguno	Ninguno	☆
model_execution_audit	Tabla	8 ago 2026, 1:31:39 p.m. UTC-5	Ninguno	Ninguno	☆
temp_data_input	Tabla	8 ago 2026, 1:50:37 p.m. UTC-5	Ninguno	Ninguno	☆
temp_data_predict	Tabla	8 ago 2026, 2:40:45 p.m. UTC-5	Ninguno	Ninguno	☆
temp_data_transformed	Tabla	8 ago 2026, 1:31:38 p.m. UTC-5	Ninguno	Ninguno	☆

Figura 11. Tablas temporales y de auditoria en el proyecto Processing.




Google Cloud BigQuery - gcp-processing-vertex-prod-us

temp_data_transformed

Esquema Detalles Vista previa Estadísticas Linaje Perfil de datos Calidad de los datos

Fila	id	periodo	masubclass	masonry_tr	lotfrontage	lotarea_trans	neighborhood	overallqual	overallcond	yearbuilt	yearremod	bmsqual	bmsfirsttype	bmsfirstpri	totalbmsf	centra
1	2452	202605	0.83333333...	0.25	0.47117546...	0.05702400...	0.22727272...	0.66666666...	0.875	0.05072463...	0.34426229...	0.33333333...	0.0	0.0	0.13404255...	
2	2452	202606	0.83333333...	0.25	0.47117546...	0.05702400...	0.22727272...	0.66666666...	0.875	0.05072463...	0.34426229...	0.33333333...	0.0	0.0	0.13404255...	
3	1857	202606	0.58333333...	0.75	0.64514258...	0.11731987...	0.45454545...	0.44444444...	0.75	0.05797101...	0.04918032...	0.33333333...	0.0	0.0	0.0	
4	1857	202605	0.58333333...	0.75	0.64514258...	0.11731987...	0.45454545...	0.44444444...	0.75	0.05797101...	0.04918032...	0.33333333...	0.0	0.0	0.0	
5	1539	202606	0.58333333...	0.25	0.32109662...	0.03599055...	0.22727272...	0.77777777...	1.0	0.13043478...	0.14754098...	0.0	0.0	0.0	0.05662847...	
6	1539	202605	0.58333333...	0.25	0.32109662...	0.03599055...	0.22727272...	0.77777777...	1.0	0.13043478...	0.14754098...	0.0	0.0	0.0	0.05662847...	

Figura 12. Vista previa de temp_data_transformed.



Google Cloud BigQuery - gcp-output-bigquery-prod-us-ee

prod_table

Descripción general Detalles Estadísticas

Tablas Gráficos Modelos Rutinas

Filtro Escribir el nombre o valor de la propiedad

ID de tabla	Tipo	Fecha de creación	Hora de vencimiento	Etiqueta	
ba_aux_modelo_universo	Tabla	8 ago 2026, 3:41:43 p.m. UTC-5	Ninguno	Ninguno	☆
ba_modelo_propension_inscripcion	Tabla	8 ago 2026, 3:41:42 p.m. UTC-5	Ninguno	Ninguno	☆

Figura 13. Tablas finales disponibles en el proyecto Output.

Google Cloud | gcp-output-bigquery-prod-us-east | big query

gcp-output-bigquery-prod-us-east / Datasets / prod_table / Tables / ba_aux_modelo_universo

ba_aux_modelo_universo

Esquema	Detalles	Vista previa	Estadísticas	Linaje	Perfil de datos	Calidad de los datos
File	id	periodo	masubclases	mazoning	lotfrontage	lotarea
1	1461	202605	20	RH	80.0	11622
2	1461	202606	20	RH	80.0	11622
3	1462	202606	20	RL	81.0	14267
4	1462	202605	20	RL	81.0	14267
5	1467	202605	20	RL	null	7980
6	1467	202606	20	RL	null	7980
7	1469	202605	20	RL	85.0	10176
8	1469	202606	20	RL	85.0	10176
9	1470	202605	20	RL	70.0	8430
10	1470	202606	20	RL	70.0	8430
11	1477	202605	20	RL	94.0	12883
12	1477	202606	20	RL	94.0	12883
13	1478	202605	20	RL	90.0	11610
14	1478	202606	20	RL	90.0	11610
15	1479	202606	20	RL	79.0	14122
16	1479	202605	20	RL	79.0	14122

Figura 14. Vista de ba_aux_modelo_universo.

Google Cloud | gcp-output-bigquery-prod-us-east | big query

gcp-output-bigquery-prod-us-east / Datasets / prod_table / Tables / ba_modelo_propension_inscripcion

ba_modelo_propension_inscripcion

Esquema	Detalles	Vista previa	Estadísticas	Linaje	Perfil de datos	Calidad de los datos
File	id	periodo	masubclases	mazoning	lotfrontage	lotarea
1	1461	202607	20	RH	80.0	11622
2	1462	202607	20	RL	81.0	14267
3	1467	202607	20	RL	null	7980
4	1469	202607	20	RL	85.0	10176
5	1470	202607	20	RL	70.0	8430
6	1477	202607	20	RL	94.0	12883
7	1478	202607	20	RL	90.0	11610
8	1479	202607	20	RL	79.0	14122
9	1480	202607	20	RL	110.0	14300
10	1483	202607	20	RL	100.0	18494
11	1488	202607	20	RL	73.0	8967
12	1489	202607	20	FV	92.0	9215
13	1490	202607	20	FV	84.0	10440
14	1493	202607	20	FV	39.0	15410
15	1503	202607	20	FV	57.0	12853
16	1505	202607	20	FV	80.0	8000

Figura 15. Vista de ba_modelo_propension_inscripcion.

Google Cloud | gcp-data-bigquery-prod-us-east | Buscar (f) recursos, documentos, productos y más

gcp-data-bigquery-prod-us-east / Datasets / hist_table / Tables / input_data

input_data

Esquema	Detalles	Vista previa	Estadísticas	Linaje	Perfil de datos	Calidad de los datos
File	id	periodo	masubclases	mazoning	lotfrontage	lotarea
1	1461	202607	20	RH	80.0	11622
2	1461	202605	20	RH	80.0	11622
3	1461	202606	20	RH	80.0	11622
4	1462	202607	20	RL	81.0	14267
5	1462	202605	20	RL	81.0	14267
6	1462	202606	20	RL	81.0	14267
7	1467	202607	20	RL	null	7980
8	1467	202605	20	RL	null	7980
9	1467	202606	20	RL	null	7980
10	1469	202607	20	RL	85.0	10176
11	1469	202605	20	RL	85.0	10176
12	1469	202606	20	RL	85.0	10176
13	1470	202607	20	RL	70.0	8430
14	1470	202605	20	RL	70.0	8430
15	1470	202606	20	RL	70.0	8430
16	1477	202607	20	RL	94.0	12883

Figura 16. Tabla fuente input_data.

Google Cloud | gcp-processing-storage-prod-us | storage

gcp-processing-storage-prod

Ubicación: us (múltiples regiones en Estados Unidos) | Clase de almacenamiento: Standard | Acceso público: No público | Protección: Borrar de forma no definitiva

Objetos

Nombre	Tamaño	Tipo	Fecha de creación	Clase de almacenamiento	Última modificación	Contextos personalizados	Acceso público	Historial de versiones	Encrypt
911699346669/	-	Carpetas	-	-	-	-	-	-	-
model/	-	Carpetas	-	-	-	-	-	-	-
pipeline_end_to_end/	-	Carpetas	-	-	-	-	-	-	-
pipeline/	-	Carpetas	-	-	-	-	-	-	-

Figura 17. Bucket con los artefactos del pipeline.

9. Resultado

La solución ejecuta de forma automatizada el procesamiento de un periodo de datos, aplica las transformaciones y el modelo de Machine Learning, y publica los resultados en BigQuery. La evidencia confirma la cadena completa: Cloud Scheduler, Cloud Run Job, Vertex AI Pipelines, BigQuery y Cloud Storage.

Archivos de referencia

- DOCUMENTACION_PROYECTO.md
- Diagrama_Proyecto.drawio
- Diagrama_GSA.drawio
- project-data-input/Dev-Project.md
- project-data-processing/Dev.Project.md
- project-data-prod/Dev.Project.md
- permissions.md de cada proyecto
- service/crun/main.py